



Application du Krigage à l'optimisation globale sous contraintes



From :
Analysis of multi-objective Kriging-based methods for
constrained global optimization

2014

Cédric Durantin · Julien Marzat · Mathieu Balesdent

Mathias LOMMEL
5MA

—
Analyse d'Incertitudes & de
sensibilité en ingénierie

Contexte

Imaginons un problème d'optimisation de la forme suivante :

$$\min_{x \in X} f(x)$$

Si la fonction à minimiser f est une “fonction boîte noire”, et qui est **très coûteuse en temps de calcul**, comment résoudre le problème ?

→ Nous pouvons approximer f ... En utilisant les **processus Gaussiens** !

Sommaire

① Régression par Processus Gaussiens

- *Équations du Krigeage*
- *Estimation du noyau de covariance*

② Optimisation sans contraintes

- *Contexte de l'optimisation*
- *Critères de recherche*
- *Algorithme EGO*
- *Comparaison des critères*

③ Optimisation sous contraintes

- *Contexte de l'optimisation*
- *Critères de recherche*
- *Comparaison des critères*

④ D'autres méthodes d'optimisation...

- *D'autres critères...*

⑤ Conclusion

Régression par processus Gaussiens

Équations du Krigage

Objectif du Krigage :

Interpoler une fonction à l'aide d'un **plan d'expérience** d'entrée, où nous connaissons la valeur de la fonction.

$$\mathcal{X} := \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \quad \mathbf{z} := \{z_1, z_2, \dots, z_n\} = \{f(\mathbf{x}_1), f(\mathbf{x}_2), \dots, f(\mathbf{x}_n)\}$$

→ f modélisée comme une trajectoire d'un processus Gaussien Y

$$Y(\mathbf{x}) = \beta(\mathbf{x}) + \varepsilon(\mathbf{x})$$

Modèle de régression
(interpolation par Krigage de la fonction)

Processus Gaussien (bruit)
(moyenne nulle et covariance stationnaire)

Équations du Krigage

$$\hat{f}(\mathbf{x}) = \hat{\beta}(\mathbf{x}) + k_0^T R^{-1}(\mathcal{X})(\mathbf{z} - \mathbb{1}_n \hat{\beta}(\mathbf{x}))$$

$\hat{f}(\mathbf{x})$: prédiction de la fonction au point $\mathbf{x}$,

$\hat{\beta}(\mathbf{x})$: estimateur de $\beta(\mathbf{x})$,

Avec : $R(\mathcal{X})$: matrice d'autocorrélation ($R_{ij}(\mathcal{X}) = R(x_i - x_j)$),

k_0 : vecteur $[R(\mathbf{x} - x_1), \dots, R(\mathbf{x} - x_n)]^T$,

$\mathbf{z}$: valeurs de f aux points de $\mathcal{X}$.

Que faire quand le noyau d'autocorrélation R est inconnu ?

Comment estimer l'estimateur de β ?

Estimation du noyau de covariance

Nous devons considérer un certain type de fonction d'autocorrélation R .

Une fonction très utilisée est la *fonction p-exponentielle* :

$$R(x - x') = \exp \left(- \sum_{i=1}^d \theta_i \cdot |x_i - x'_i|^{p_i} \right) \quad \text{avec } 0 < p_i \leq 2$$

En version 1D : $R(h) = e^{-\theta \cdot |h|^p}$

Nous devons donc estimer 3 quantités : $\hat{\beta}$, $\hat{\theta}$ et $\hat{p}$

(D'autres noyaux existent : *Matern*, *RationalQuadratic*, *ExpSineSquared*,...)

Estimation du noyau de covariance

→ Estimation par *maximum de vraisemblance* (MLE)

Vraisemblance des observations $\mathbf{z}$:

$$\mathcal{L}(\beta, \sigma^2, \theta, p | \mathbf{z}) = \frac{1}{(2\pi\sigma^2)^{n/2} \cdot \sqrt{\det(R(\theta, p))}} \cdot \exp \left[-\frac{(\mathbf{z} - \beta)^T \mathbf{R}^{-1}(\theta, p)(\mathbf{z} - \beta)}{2\sigma^2} \right]$$

En maximisant cette quantité, on obtient

$$\hat{\beta} = \frac{\mathbf{1}^T \mathbf{R}^{-1} \mathbf{z}}{\mathbf{1}^T \mathbf{R}^{-1} \mathbf{1}}, \quad \hat{\sigma}^2 = \frac{(\mathbf{z} - \hat{\beta})^T \mathbf{R}^{-1} (\mathbf{z} - \hat{\beta})}{n}.$$

→ On détermine enfin $\hat{\theta}$ et $\hat{p}$: $\theta, p = \underset{\theta, p}{\operatorname{argmax}} \ln \mathcal{L}(\hat{\beta}, \hat{\sigma}^2, \theta, p | \mathbf{z})$

En résumé...

On souhaite estimer une fonction f , en la modélisant comme la trajectoire d'un *processus gaussien*.

Données : un *plan d'expérience*, et la *valeur de f sur ce plan*

- 1 - Choisir une *forme standard pour le noyau de corrélation* de la fonction
- 2 - Estimation des paramètres de ce noyau (*θ et p*)
- 3 - A l'aide des paramètres obtenus, estimation de *β et σ*

... et nous pouvons calculer l'interpolation de f pour n'importe quel x

Optimisation sans contraintes

Contexte de l'optimisation

Considérons un problème suivant :

$$\hat{x} \in \underset{x \in X}{\operatorname{argmin}} f(x)$$

f est supposée **coûteuse** : on souhaite trouver le minimum en un **minimum d'évaluations de la fonction**

Idée de raisonnement :

- On démarre avec un *plan d'expérience initial (noté X)*
- On interpole f sur l'ensemble du domaine X (*estimation des paramètres de Krigage*)
- Tant qu'on ne se trouve pas "*suffisamment proche du minimum*" ?
 - *Trouver un nouveau point* x_{new} "intéressant" ?
 - Interpolation de f sur le nouveau plan d'expérience (*estimation des paramètres de Krigage*)

Critères de recherche

Objectif : Trouver un point *"intéressant"*

→ un point qui va nous *"rapprocher du minimum"*

A n'importe quel instant, on note $z_{\min} = \min\{z_1, \dots, z_n\}$ le minimum de f sur le plan d'expérience actuel.

Définition de l'*amélioration* :
$$I(\mathbf{x}) = \begin{cases} z_{\min} - \hat{f}(\mathbf{x}), & \text{si } \hat{f}(\mathbf{x}) < z_{\min} \\ 0, & \text{sinon} \end{cases}$$

Cette quantité correspond à l'*amélioration potentielle de notre "meilleur candidat"*.

Critères de recherche

En utilisant l'amélioration potentielle, nous pouvons trouver un nouveau point "intéressant", en maximisant :

- La **probabilité d'amélioration** (*probability of improvement*) :

$$PI(\mathbf{x}) = \mathcal{P}[Y(\mathbf{x}) \leq z_{\min}]$$

On sélectionne le x dont la probabilité de trouver une meilleure borne inférieure est maximale.

- L'**amélioration espérée** (*expectation of improvement*) :

$$EI(\mathbf{x}) = \mathbb{E}[I(\mathbf{x})]$$

On sélectionne le x qui maximise l'amélioration espérée de la borne inférieure.

Sous l'hypothèse de normalité de Y , on obtient :

$$PI(\mathbf{x}) = \Phi\left(\frac{z_{\min} - \hat{f}(\mathbf{x})}{\hat{s}(\mathbf{x})}\right) \quad EI(\mathbf{x}) = (z_{\min} - \hat{f}(\mathbf{x})) \cdot \Phi\left(\frac{z_{\min} - \hat{f}(\mathbf{x})}{\hat{s}(\mathbf{x})}\right) + \hat{s}(\mathbf{x}) \cdot \Phi\left(\frac{z_{\min} - \hat{f}(\mathbf{x})}{\hat{s}(\mathbf{x})}\right)$$

Algorithme EGO (Efficient Global Optimisation)

Initialisations :

- Détermination d'un plan d'expérience initial
- *Estimation des paramètres de Krigeage*

Tant que le critère d'arrêt n'est pas atteint :

- Choisir x_{new} qui maximise le critère (PI ou EI)
- Calcul de $z_{new} = f(x_{new})$
- Ajout de x_{new} au plan d'expérience
- *Estimation des paramètres de Krigeage*

Algorithme EGO (Efficient Global Optimisation)

Initialisations :

- Détermination d'un plan d'expérience initial
- *Estimation des paramètres de Krigeage*

*Nombre d'évaluations
maximum de la fonction
(en fonction du budget)*

Tant que le critère d'arrêt n'est pas atteint :

- Choisir x_{new} qui maximise le critère (PI ou EI)
- Calcul de $z_{new} = f(x_{new})$
- Ajout de x_{new} au plan d'expérience
- *Estimation des paramètres de Krigeage*

Stagnation du critère

Comparaison des critères

PI

EI

Propose des points très proches du meilleur point actuel

Ne permet pas d'explorer des zones où il y a peu de points

→ Convergence plus lente


Meilleure exploration de l'espace

Prend en compte la variance de la prédiction


→ Convergence plus rapide

Comparaison des critères


Exemple pratique : minimisation de la fonction étudiée en TP



PI




EI




Comparaison des critères


Exemple pratique : minimisation de la fonction étudiée en TP



PI



EI





Optimisation sous contraintes



Contexte de l'optimisation

On considère désormais des *contraintes* :

$$\begin{aligned} \hat{\mathbf{x}} &\in \arg \min_{\mathbf{x} \in \mathbb{X}} f(\mathbf{x}), \\ \text{s.t. } \mathbf{g}(\mathbf{x}) &\leq \mathbf{0}. \end{aligned}$$

On suppose que $\mathbf{g}$ ne peut être connue que par des *évaluations coûteuses*

→ Chaque contrainte sera donc approximée par un modèle de Krigeage

On se propose de résoudre ce nouveau problème avec le *même algorithme que dans le cas sans contraintes*

→ Nous allons explorer de *nouveaux critères à maximiser* dans la recherche de nouveaux points

Critères de recherche

1 - Probabilité de faisabilité

Cette mesure est analogue à PI . On note $\hat{g}_i$ la prédiction de la contrainte i par Krigeage, et $\hat{s}_{g,i}$ sa variance.

$$PF_i(\mathbf{x}) = \Phi \left(-\frac{\hat{g}_i(\mathbf{x})}{\hat{s}_{g,i}(\mathbf{x})} \right) \quad \text{Probabilité de faisabilité de la contrainte } i$$

En considérant que nous avons m contraintes : $EI \times PF(\mathbf{x}) = EI(\mathbf{x}) \prod_{i=1}^m PF_i(\mathbf{x})$

→ L'importance de EI est amenée à 0 là où il y a une faible probabilité pour une des contraintes.

Critères de recherche

2 - Contraindre l'amélioration espérée

Dans ce second cas, on propose de maximiser EI sous les contraintes du problème global.

$$\begin{array}{ll} \max_{\mathbf{x} \in \mathbb{X}} & \text{EI}(\mathbf{x}), \\ \text{s.t.} & \widehat{\mathbf{g}}(\mathbf{x}) \leq 0. \end{array}$$

*Nous devons ici résoudre un problème
d'optimisation sous contraintes*

- Cette mesure est fortement dépendante de la *précision d'interpolation des contraintes g*
- Si les contraintes sont actives, ce critère propose des *points proches de leurs frontières* ($g(\mathbf{x}) = 0$)

Critères de recherche

3 - Violation espérée

Dans ce dernier cas, on propose de maximiser une nouvelle quantité, qui est proche de l'amélioration espérée :

$$EV_i(\mathbf{x}) = -\widehat{g}_i(\mathbf{x})\Phi\left(-\frac{\widehat{g}_i(\mathbf{x})}{\widehat{s}_{g_i}(\mathbf{x})}\right) + \widehat{s}_{g_i}\phi\left(-\frac{\widehat{g}_i(\mathbf{x})}{\widehat{s}_{g_i}(\mathbf{x})}\right)$$

→ *Ce critère est grand :*

- *là où les contraintes sont susceptibles de ne pas être violées*
- *là où l'incertitude des contraintes est grande*

Nouveau problème de maximisation :

$$\begin{array}{ll} \max_{\mathbf{x} \in \mathbb{X}} & EI(\mathbf{x}), \\ \text{s.t.} & EV_i(\mathbf{x}) \geq t_{EV} \quad \text{for } i = 1, \dots, m \end{array}$$

Critères de recherche

3 - Violation espérée

Dans ce dernier cas, on propose de maximiser une nouvelle quantité, qui est proche de l'amélioration espérée :

$$EV_i(\mathbf{x}) = -\widehat{g}_i(\mathbf{x})\Phi\left(-\frac{\widehat{g}_i(\mathbf{x})}{\widehat{s}_{g_i}(\mathbf{x})}\right) + \widehat{s}_{g_i}\phi\left(-\frac{\widehat{g}_i(\mathbf{x})}{\widehat{s}_{g_i}(\mathbf{x})}\right)$$

→ *Ce critère est grand :*

- *là où les contraintes sont susceptibles de ne pas être violées*
- *là où l'incertitude des contraintes est grande*

Nouveau problème de maximisation :

$$\begin{array}{ll} \max_{\mathbf{x} \in \mathbb{X}} & EI(\mathbf{x}), \\ \text{s.t.} & EV_i(\mathbf{x}) \geq t_{EV} \text{ for } i = 1, \dots, m \end{array}$$

Seuil fixé

Comparaison des critères


EI x PF	Constrained EI	EV
<i>Contraintes bien délimitées par la proba de faisabilité</i>	<i>Offre de bons résultats, avec moins d'appels de f que EI x PF.</i>	<i>Critère très conservatif que CEI, dû à la prise en compte de la variance.</i>
<i>Seul critère qui n'échoue pas sur les 4 tests de l'article</i>	<i>Peut ajouter des points vers un minimum local.</i>	<i>Pire résultats sur les 4 instances de test.</i>
<i>Bon résultats en termes de précision sur la contrainte, même si moins précis que CEI.</i>	<i>N'ajoute pas spécifiquement des points où l'incertitude sur la contrainte est forte.</i>	
	<i>A du mal à converger dans le cas de régions disjointes.</i>	

Comparaison des critères


Exemple pratique : minimisation de la fonction étudiée en TP

+ *Sous la contrainte linéaire simple : $x \leq 0.5$*

$$\begin{array}{ll} \min_x & f(x) \\ \text{s. c.} & x - \frac{1}{2} \leq 0 \\ & x \in [0, 1] \end{array}$$



Comparaison des critères




EI x PF

Contraintes bien délimitées par la proba de faisabilité

Seul critère qui n'échoue pas sur les 4 tests de l'article

Bon résultats en termes de précision sur la contrainte, même si moins précis que CEI.

Comparaison des critères




EI x PF

***Contraintes bien délimitées
par la proba de faisabilité***

*Seul critère qui n'échoue pas
sur les 4 tests de l'article*

*Bon résultats en termes de
précision sur la contrainte,
même si moins précis que CEI.*

Comparaison des critères



Constrained EI


Offre de bons résultats, avec moins d'appels de f que ElxPF.

Peut ajouter des points vers un minimum local.

N'ajoute pas spécifiquement des points où l'incertitude sur la contrainte est forte.

A du mal à converger dans le cas de régions disjointes.

Comparaison des critères



Constrained EI


Offre de bons résultats, avec moins d'appels de f que ElxPF.

Peut ajouter des points vers un minimum local.

N'ajoute pas spécifiquement des points où l'incertitude sur la contrainte est forte.

A du mal à converger dans le cas de régions disjointes.

Comparaison des critères




EV

Critère très conservatif que CEI, dû à la prise en compte de la variance.

Pire résultats sur les 4 instances de test.

Comparaison des critères



EV

Critère très conservatif que CEI, dû à la prise en compte de la variance.



Pire résultats sur les 4 instances de test.

Mais...

Si on conserve la même région pour la contrainte, mais légèrement différente :

$$\begin{aligned} \min_x & f(x) \\ \text{s. c. } & \cos(2\pi x + \frac{\pi}{2}) \leq 0 \\ & x \in [0, 1] \end{aligned}$$

Pas de convergence en 20 itérations...





D'autres méthodes d'optimisation...



D'autres critères...

Les critères *simples* (uni-objectif) ne permettent pas un bon compromis entre :

- une *évaluation précise* de l'optimum
- une bonne *fiabilité* de la solution
- une *approximation précise des contraintes*

Une alternative est d'utiliser des *critères bi-objectifs*.

Plutôt que de transformer le problème contraint en un problème non contraint, nous proposons de *traiter l'EI et le PF comme des objectifs individuels à optimiser* :

$$\max_{\mathbf{x} \in \mathbb{X}} \left\{ \text{EI}(\mathbf{x}), \prod_{i=1}^m \text{PF}_i(\mathbf{x}) \right\}$$

D'autres critères...

La *variance de l'approximation* des contraintes par Krigeage n'est pas explicitement prise en compte dans le bi-objectif.

Réduire la variance peut permettre d'atteindre un minimum global plus proches des bornes des contraintes prédites (dans le cas de contraintes actives).

A cet effet, nous pouvons construire un tri-objectif, *considérant la variance de la prédiction de contraintes* :

$$\max_{\mathbf{x} \in \mathbb{X}} \left\{ \text{EI}(\mathbf{x}), \prod_{i=1}^m \text{PF}_i(\mathbf{x}), - \sum_{i=1}^m \hat{s}_{g_i} \right\}$$

D'autres critères...

Intérêts des critères multiples :

- permettent un *plus grand choix* de points d'entrée
- permet un *compromis acceptable entre plusieurs objectifs*

Le nouveau point est choisi en maximisant le produit de l'EI et du PF

Les critères simples sont aussi fortement *multimodaux*

→ *traiter le problème comme un objectif multiple peut obtenir de meilleures solutions*

Conclusion